



Министерство науки и высшего образования Российской Федерации
Федеральное государственное автономное образовательное учреждение
высшего образования
«Московский государственный технический университет
имени Н.Э. Баумана
(национальный исследовательский университет)»
(МГТУ им. Н.Э. Баумана)

ФАКУЛЬТЕТ Информатика и системы управления

КАФЕДРА Системы обработки информации и управления

ОТЧЕТ
ПО ЛАБОРАТОРНОЙ РАБОТЕ №2
ПО ДИСЦИПЛИНЕ
«МЕТОДЫ МАШИННОГО ОБУЧЕНИЯ»
НА ТЕМУ:
Обработка признаков (часть 2).

Студент ИУ5И-22М
(Группа)

Хуан Лэй
(Подпись, дата) (И.О.Фамилия)

Преподаватель

Ю.Е.Гапанюк
(Подпись, дата) (И.О.Фамилия)

2026 г.

ВВЕДЕНИЕ

Обработка признаков (Feature Engineering) в машинном обучении - это процесс создания, преобразования и выбора наиболее релевантных признаков (features) из исходных данных для улучшения производительности и точности моделей машинного обучения. Этот процесс включает в себя: очистку данных и удаление аномалий; выделение признаков для решения задачи; подготовку данных.

Цель лабораторной работы: изучение продвинутых способов предварительной обработки данных для дальнейшего формирования моделей.

ЗАДАНИЕ

Выбрать один или несколько наборов данных (датасетов) для решения следующих задач. Каждая задача может быть решена на отдельном датасете, или несколько задач могут быть решены на одном датасете. Просьба не использовать датасет, на котором данная задача решалась в лекции.

Для выбранного датасета (датасетов) на основе материалов лекций решить следующие задачи:

1. Масштабирование признаков (не менее чем тремя способами);
2. Обработку выбросов для числовых признаков (по одному способу для удаления выбросов и для замены выбросов);
3. Обработку по крайней мере одного нестандартного признака (который не является числовым или категориальным);
4. Отбор признаков:
 - один метод из группы методов фильтрации (filter methods);
 - один метод из группы методов обертывания (wrapper methods);
 - один метод из группы методов вложений (embedded methods).

ХОД ВЫПОЛНЕНИЯ РАБОТЫ

Часть 1. Текстовое описание набора данных

Для выполнения лабораторной работы был выбран набор данных California Housing (данные о ценах на жилье в Калифорнии). Этот набор данных содержит информацию о различных факторах, влияющих на стоимость домов в разных районах Калифорнии.

Набор данных содержит следующие признаки:

- MedInc (медианный доход в районе)
- HouseAge (медианный возраст домов)
- AveRooms (среднее количество комнат)
- AveBedrms (среднее количество спален)
- Population (численность населения)
- AveOccup (средняя оссипансу)
- Latitude (широта)
- Longitude (долгота)

Целевая переменная: target (медианная стоимость дома)

```

=====
БИБЛИОТЕКИ УСПЕШНО ЗАГРУЖЕНЫ
所有库已成功加载
=====

=====
ИНФОРМАЦИЯ О ДАТАСЕТЕ CALIFORNIA HOUSING
加州房价数据集信息
=====

Размер датасета / 数据集大小: 20640 строк x 9 столбцов

Признаки / 特征:
1. MedInc
2. HouseAge
3. AveRooms
4. AveBedrms
5. Population
6. AveOccup
7. Latitude
8. Longitude

Целевая переменная / 目标变量: target (стоимость дома / 房价)

```

Рисунок 1: Информация о наборе данных California Housing

ПЕРВЫЕ 5 СТРОК / 前5行数据									
	MedInc	HouseAge	AveRooms	AveBedrms	Population	AveOccup	Latitude	Longitude	target
0	8.3252	41.0	6.984127	1.023810	322.0	2.555556	37.88	-122.23	4.526
1	8.3014	21.0	6.238137	0.971880	2401.0	2.109842	37.86	-122.22	3.585
2	7.2574	52.0	8.288136	1.073446	496.0	2.802260	37.85	-122.24	3.521
3	5.6431	52.0	5.817352	1.073059	558.0	2.547945	37.85	-122.25	3.413
4	3.8462	52.0	6.281853	1.081081	565.0	2.181467	37.85	-122.25	3.422

Рисунок 2: Первые 5 строк набора данных California Housing

Часть 2. Масштабирование признаков

Масштабирование признаков - это изменение диапазона измерения признака с целью улучшения качества построения модели. Многие алгоритмы машинного обучения устроены таким образом, что признаки с меньшей амплитудой оказывают меньшее влияние на процесс построения модели. Поэтому перед построением моделей рекомендуется масштабировать данные.

В данной работе были использованы четыре метода масштабирования признаков: Min-Max Scaling, Standard Scaling (Z-score), Robust Scaling и MaxAbs Scaling. В качестве тестового признака был выбран MedInc (медианный доход).

Код реализации:

```
```python
from sklearn.preprocessing import MinMaxScaler, StandardScaler,
RobustScaler, MaxAbsScaler

Min-Max Scaling
scaler_minmax = MinMaxScaler()
df['MedInc_minmax'] = scaler_minmax.fit_transform(df[['MedInc']])

Standard Scaling
scaler_std = StandardScaler()
df['MedInc_standard'] = scaler_std.fit_transform(df[['MedInc']])

Robust Scaling
scaler_robust = RobustScaler()
df['MedInc_robust'] = scaler_robust.fit_transform(df[['MedInc']])

MaxAbs Scaling
scaler_maxabs = MaxAbsScaler()
df['MedInc_maxabs'] = scaler_maxabs.fit_transform(df[['MedInc']])
```

Результаты масштабирования представлены в таблице 1.

Таблица 1 - Сравнение методов масштабирования

Method	Min	Max	Mean	Std
Original	0.4999	15.0001	3.8707	1.8998
Min-Max	0.0000	1.0000	0.2325	0.1310
Standard	-1.7743	5.8583	0.0000	1.0000
Robust	-1.3923	5.2597	0.1541	0.8715
MaxAbs	0.0333	1.0000	0.2580	0.1267

На рисунке 3 представлены гистограммы и боксплоты распределения признака MedInc до и после применения различных методов масштабирования. Видно, что все методы сохраняют форму распределения, но изменяют масштаб данных. Min-Max сжимает данные в диапазон  $[0,1]$ , Standard Scaling центрирует данные относительно нуля со стандартным отклонением 1, Robust Scaling использует медиану и интерквартильный размах, что делает его устойчивым к выбросам.




Рисунок 3: Визуализация результатов масштабирования признака MedInc



### Часть 3. Обработка выбросов для числовых признаков

Выбросы - это элементы выборки, существенно отличающиеся от остальных элементов. Выбросы негативно влияют на построение модели, поэтому их необходимо обрабатывать. В данной работе использован метод обнаружения выбросов на основе межквартильного размаха (IQR). Для признака AveRooms (среднее количество комнат) были применены два подхода: удаление выбросов и замена выбросов граничными значениями.

Код реализации:

```
```python
# Обнаружение выбросов методом IQR
Q1 = df['AveRooms'].quantile(0.25)
Q3 = df['AveRooms'].quantile(0.75)
IQR = Q3 - Q1
lower_bound = Q1 - 1.5 * IQR
upper_bound = Q3 + 1.5 * IQR
# Удаление выбросов
df_no_outliers = df[(df['AveRooms'] >= lower_bound) & (df['AveRooms'] <=
upper_bound)]
# Замена выбросов граничными значениями
df_clipped['AveRooms_clipped'] =
df_clipped['AveRooms'].clip(lower=lower_bound, upper=upper_bound)
```

Результаты обработки выбросов:

- Q1 (25% квартиль): 4.44
- Q3 (75% квартиль): 6.05
- IQR (межквартильный размах): 1.61

- Нижняя граница: 2.02
- Верхняя граница: 8.47
- Количество выбросов: 511 (2.48% от всех данных)
- После удаления: 20640 → 20129 записей
- После замены: min стал 2.02, max стал 8.47

На рисунке 4 представлены гистограммы распределения признака AveRooms до обработки, после удаления выбросов и после замены выбросов. Видно, что оба метода эффективно устраняют влияние выбросов на распределение данных.



Рисунок 4: Визуализация обработки выбросов признака AveRooms

Часть 4. Обработка нестандартного признака (дата/время)

Нестандартные признаки - это признаки, которые не являются ни числовыми, ни категориальными. Примерами таких признаков являются даты, время, текст, координаты и т.д. В данной работе в качестве нестандартного признака была создана и обработана дата (`purchase_date`).

Основные методы обработки дат:

1. Извлечение компонентов даты (год, месяц, день, день недели, квартал)
2. Создание циклических признаков с использованием $\sin/\cos$ преобразования
3. Создание признаков на основе разницы дат

Код реализации:

```
```python
Извлечение компонентов даты
date_df['year'] = date_df['purchase_date'].dt.year
date_df['month'] = date_df['purchase_date'].dt.month
date_df['day'] = date_df['purchase_date'].dt.day
date_df['day_of_week'] = date_df['purchase_date'].dt.dayofweek
date_df['quarter'] = date_df['purchase_date'].dt.quarter

Циклическое кодирование
date_df['month_sin'] = np.sin(2 * np.pi * date_df['month'] / 12)
date_df['month_cos'] = np.cos(2 * np.pi * date_df['month'] / 12)

Признаки на основе разницы дат
reference_date = pd.Timestamp('2020-01-01')
date_df['days_since_reference'] = (date_df['purchase_date'] -
reference_date).dt.days
date_df['is_weekend'] = (date_df['day_of_week'] >= 5).astype(int)
```

На рисунке 5 представлены результаты обработки нестандартного признака. Временные признаки были успешно добавлены в основной датасет.

【3.2】ЦИКЛИЧЕСКИЕ ПРИЗНАКИ (SIN/COS) ДЛЯ МЕСЯЦА  
月份的循环特征 (sin/cos)

-----  
Циклические признаки / 循环特征:

- month\_sin, month\_cos (для месяца / 用于月份)
- dow\_sin, dow\_cos (для дня недели / 用于星期几)

Пример / 示例:

	id	purchase_date	month	month_sin	month_cos	day_of_week	dow_sin	dow_cos
0	1	2020-04-12	4	8.660254e-01	-5.000000e-01	6	-0.781831	0.62349
1	2	2020-12-15	12	-2.449294e-16	1.000000e+00	1	0.781831	0.62349
2	3	2020-09-29	9	-1.000000e+00	-1.836970e-16	1	0.781831	0.62349
3	4	2020-04-19	4	8.660254e-01	-5.000000e-01	6	-0.781831	0.62349
4	5	2020-03-16	3	1.000000e+00	6.123234e-17	0	0.000000	1.00000

Рисунок 5: Результаты обработки даты как нестандартного признака

## Часть 5. Отбор признаков

Отбор признаков (feature selection) - это процесс выбора наиболее важных признаков для построения модели. Отбор признаков позволяет уменьшить размерность данных, сократить время обучения и повысить интерпретируемость модели.

### 5.1. Метод фильтрации (Filter Method) - SelectKBest + Mutual Information

Метод фильтрации оценивает каждый признак независимо от других, используя статистические критерии. В данной работе использован метод взаимной информации (Mutual Information) для оценки важности признаков.

Код реализации:

```
```python
from sklearn.feature_selection import SelectKBest, mutual_info_regression
selector_mi = SelectKBest(score_func=mutual_info_regression, k=4)
X_mi_selected = selector_mi.fit_transform(X, y)
```

Результаты взаимной информации:

- Longitude: 0.400147
- MedInc: 0.387097
- Latitude: 0.370763
- AveRooms: 0.102874
- AveOccup: 0.072716
- HouseAge: 0.033368
- AveBedrms: 0.024149
- Population: 0.020878

Выбранные признаки (k=4): MedInc, AveRooms, Latitude, Longitude




Рисунок 6: Визуализация результатов метода фильтрации (Mutual Information)

5.2. Метод обертывания (Wrapper Method) - RFE

Метод обертывания использует модель машинного обучения для оценки качества подмножеств признаков. В данной работе использован метод рекурсивного исключения признаков (RFE) с линейной регрессией.

Код реализации:

```
from sklearn.feature_selection import RFE
from sklearn.linear_model import LinearRegression
rfe = RFE(estimator=LinearRegression(), n_features_to_select=4)
rfe.fit(X, y)
```

Результаты RFE:

Ранг 1 (выбраны): MedInc, AveBedrms, Latitude, Longitude

Ранг 2: AveRooms

Ранг 3: HouseAge

Ранг 4: AveOccup

Ранг 5: Population




Рисунок 7: Визуализация результатов метода обертывания (RFE)

5.3. Вложенный метод (Embedded Method) - Lasso и Random Forest

Вложенные методы выполняют отбор признаков в процессе обучения модели. В данной работе использованы два подхода: Lasso (L1-регуляризация) и Random Forest (важность признаков).

Код реализации:

```
from sklearn.linear_model import Lasso
from sklearn.ensemble import RandomForestRegressor
# Lasso
lasso = Lasso(alpha=0.01)
lasso.fit(X, y)
# Random Forest
rf = RandomForestRegressor(n_estimators=100)
rf.fit(X, y)
```

Результаты Lasso: выбранные признаки с ненулевыми коэффициентами - MedInc, AveRooms, Latitude, Longitude.

Результаты Random Forest (важность выше среднего): MedInc, Latitude, Longitude, AveOccup, AveRooms.




Рисунок 8: Визуализация результатов вложенных методов (Lasso и Random Forest)

Часть 6. Сравнение методов отбора признаков

Таблица 2 - Сравнение методов отбора признаков

Method	Selected Features Count	Selected Features
Filter (Mutual Info)	4	MedInc, AveRooms, Latitude, Longitude
Wrapper (RFE)	4	MedInc, AveBedrms, Latitude, Longitude
Embedded (Lasso)	4	MedInc, AveRooms, Latitude, Longitude
Embedded (Random Forest)	5	MedInc, Latitude, Longitude, AveOccup, AveRooms

Из таблицы видно, что все методы выделяют MedInc, Latitude и Longitude как наиболее важные признаки для прогнозирования стоимости жилья. Это соответствует реальной ситуации, так как расположение (широта и долгота) и уровень дохода в районе являются ключевыми факторами, определяющими цены на недвижимость.

```

=====
СРАВНЕНИЕ МЕТОДОВ ОТБОРА ПРИЗНАКОВ
FEATURE SELECTION METHODS COMPARISON
=====
Method Selected Features Count Selected Features
Filter (Mutual Info) 4 MedInc, AveRooms, Latitude, Longitude
Wrapper (RFE) 4 MedInc, AveBedrms, Latitude, Longitude
Embedded (Lasso) 8 MedInc, AveBedrms, HouseAge, Population, AveOccup, AveRooms, Latitude, Longitude
Embedded (Random Forest) 2 MedInc, AveOccup
=====

```

Рисунок 9: Сравнительная диаграмма методов отбора признаков

ЗАКЛЮЧЕНИЕ

В ходе выполнения данной лабораторной работы был проведен комплексный анализ обработки признаков на основе набора данных California Housing.

Были выполнены следующие задачи:

1. Масштабирование признаков:

- Применены 4 метода масштабирования: Min-Max, Standard, Robust и MaxAbs

- Все методы сохранили форму распределения исходных данных
- Min-Max масштабирование сжало данные в диапазон $[0, 1]$
- Standard Scaling центрировал данные ($\text{mean}=0$, $\text{std}=1$)
- Robust Scaling показал устойчивость к выбросам

2. Обработка выбросов:

- Обнаружено 511 выбросов (2.48%) в признаке AveRooms

- Применены два подхода: удаление выбросов и замена граничными значениями

- Оба метода эффективно устранили влияние аномальных значений

3. Обработка нестандартного признака:

- Создан и обработан признак "дата"
- Извлечены компоненты даты (год, месяц, день, день недели, квартал)
- Созданы циклические признаки ($\sin/\cos$) для учета периодичности

4. Отбор признаков:

- Filter method (Mutual Information): выбраны MedInc, AveRooms, Latitude, Longitude

- Wrapper method (RFE): выбраны MedInc, AveBedrms, Latitude, Longitude

- Embedded methods (Lasso и Random Forest): подтвердили важность MedInc, Latitude и Longitude

Результаты проведенного анализа подтверждают, что правильная предобработка данных и отбор признаков являются ключевыми этапами в построении эффективных моделей машинного обучения. Наиболее важными признаками для прогнозирования стоимости жилья являются расположение (Latitude, Longitude) и уровень дохода (MedInc), что соответствует реальным экономическим закономерностям.

ПРИЛОЖЕНИЕ

Полный код программы приведен в Jupyter Notebook, прилагаемом к отчету.