



Министерство науки и высшего образования Российской Федерации
Федеральное государственное автономное образовательное учреждение
высшего образования
«Московский государственный технический университет
имени Н.Э. Баумана
(национальный исследовательский университет)»
(МГТУ им. Н.Э. Баумана)

ФАКУЛЬТЕТ Информатика и системы управления

КАФЕДРА Системы обработки информации и управления

ОТЧЕТ

ПО РУБЕЖНЫЙ КОНТРОЛЬ №1

ПО ДИСЦИПЛИНЕ «МЕТОДЫ МАШИННОГО ОБУЧЕНИЯ»

ВАРИАНТ 19

Студент ИУ5И-22М
(Группа)

(Подпись, дата) Хуан Лэй
(И.О.Фамилия)

Преподаватель

(Подпись, дата) Ю.Е.Гапанюк
(И.О.Фамилия)

2026 г.

ВВЕДЕНИЕ

Для студентов групп ИУ5-21М, ИУ5-22М, ИУ5-23М, ИУ5-24М, ИУ5-25М
номер варианта = номер в списке группы.

Для студентов групп ИУ5И-21М, ИУ5И-22М, ИУ5И-23М, ИУ5И-24М,
ИУ5И-25М номер варианта = 15 + номер в списке группы.

Для студентов групп ИУ5-25МВ номер варианта = 20 + номер в списке
группы.

Дополнительные требования по группам:

- Для студентов групп ИУ5-21М, ИУ5И-21М - для пары произвольных колонок данных построить график "Диаграмма рассеяния".
- Для студентов групп ИУ5-22М, ИУ5И-22М - для произвольной колонки данных построить гистограмму.
- Для студентов групп ИУ5-23М, ИУ5И-23М - для произвольной колонки данных построить график "Ящик с усами (boxplot)".
- Для студентов группы ИУ5-24М, ИУ5И-24М - для произвольной колонки данных построить график "Скрипичная диаграмма (violin plot)".
- Для студентов группы ИУ5-25МВ - для произвольной колонки данных построить парные диаграммы (pairplot).

Каждая задача предполагает использование набора данных. Набор данных выбирается Вами произвольно с учетом следующих условий:

- Вы можете использовать один набор данных для решения всех задач, или решать каждую задачу на своем наборе данных.
- Набор данных должен отличаться от набора данных, который использовался в лекции для решения рассматриваемой задачи.

- Вы можете выбрать произвольный набор данных (например тот, который Вы использовали в лабораторных работах) или создать собственный набор данных.

- Выбранный или созданный Вами набор данных должен удовлетворять условиям поставленной задачи.

Полученные варианты:

- Номер варианта = $15 + 4 = 19$

- Номер задачи №1: 19

Задача №19 - Для набора данных проведите масштабирование данных для одного (произвольного) числового признака с использованием метода "Mean Normalisation".

- Номер задачи №2: 39

Задача №39 - Для набора данных проведите процедуру отбора признаков (feature selection). Используйте класс SelectPercentile для 10% лучших признаков, и метод, основанный на взаимной информации.

Дополнительные требования по группам:

- Для студентов групп ИУ5-22М, ИУ5И-22М - для произвольной колонки данных построить гистограмму.

ХОД ВЫПОЛНЕНИЯ РАБОТЫ

Часть 1. Текстовое описание набора данных

Для выполнения всех задач был использован единый набор данных: Wine Dataset (набор данных о винах). Этот набор данных взят из библиотеки scikit-learn и широко используется для задач классификации и отработки методов предобработки данных.

Набор данных содержит результаты химического анализа 178 образцов вина из трех различных сортов (типов) виноградной культуры в Италии. Данный набор данных отличается от того, который использовался в лекции, что соответствует требованию задания.

Набор данных содержит 13 числовых признаков:

1. Alcohol (алкоголь)
2. Malic acid (яблочная кислота)
3. Ash (зола)
4. Alcalinity of ash (щелочность золы)
5. Magnesium (магний)
6. Total phenols (общее количество фенолов)
7. Flavanoids (флавоноиды)
8. Nonflavanoid phenols (нефлавоноидные фенолы)
9. Proanthocyanins (проантоцианины)
10. Color intensity (интенсивность цвета)
11. Hue (оттенок)
12. OD280/OD315 of diluted wines (показатель преломления)
13. Proline (пролин)

Целевая переменная: тип вина (3 класса).

```
# Загрузка набора данных Wine
# 加载葡萄酒数据集

wine = load_wine()

# Создание DataFrame с признаками
# 创建特征数据的DataFrame
df = pd.DataFrame(wine.data, columns=wine.feature_names)

# Добавление целевой переменной
# 添加目标变量
df['target'] = wine.target

# Вывод информации о данных
# 输出数据信息
print("=" * 60)
print("НАБОР ДАННЫХ: WINE DATASET")
print("数据集: 葡萄酒数据集")
print("=" * 60)
print(f"Количество образцов: {df.shape[0]}")
print(f"样本数量: {df.shape[0]}")
print(f"Количество признаков: {df.shape[1] - 1} (13 признаков + 1 целевая переменная)")
print(f"特征数量: {df.shape[1] - 1} (13个特征 + 1个目标变量)")
print(f"Типы вин: {wine.target_names}")
print(f"葡萄酒类型: {wine.target_names}")
print("=" * 60)

df.head()
```

```
=====
НАБОР ДАННЫХ: WINE DATASET
数据集: 葡萄酒数据集
=====
Количество образцов: 178
样本数量: 178
Количество признаков: 13 (13 признаков + 1 целевая переменная)
特征数量: 13 (13个特征 + 1个目标变量)
Типы вин: ['class_0' 'class_1' 'class_2']
葡萄酒类型: ['class_0' 'class_1' 'class_2']
=====
```

Рисунок 1: Информация о наборе данных Wine Dataset

alcohol	malic_acid	ash	alkalinity_of_ash	magnesium	total_phenols	flavonoids
14.23	1.71	2.43	15.6	127.0	2.80	3.06
13.20	1.78	2.14	11.2	100.0	2.65	2.76
13.16	2.36	2.67	18.6	101.0	2.80	3.24
14.37	1.95	2.50	16.8	113.0	3.85	3.49
13.24	2.59	2.87	21.0	118.0	2.80	2.69

nonflavanoid phenols	proanthocyanins	color_intensity	hue	od280/od315_of_diluted_wines	proline
0.28	2.29	5.64	1.04	3.92	1065.0
0.26	1.28	4.38	1.05	3.40	1050.0
0.30	2.81	5.68	1.03	3.17	1185.0
0.24	2.18	7.80	0.86	3.45	1480.0
0.39	1.82	4.32	1.04	2.93	735.0

Рисунок 2: Первые 5 строк набора данных Wine Dataset

Часть 2. Задача №16

Задача №19 - Для набора данных проведите масштабирование данных для одного (произвольного) числового признака с использованием метода "Mean Normalisation".

Для выполнения задачи был выбран признак 'alcohol' (содержание алкоголя). Метод Mean Normalisation преобразует данные по формуле:

$$X_{\text{norm}} = (X - \text{mean}(X)) / (\text{max}(X) - \text{min}(X))$$

После преобразования данные имеют среднее значение, равное 0, и находятся в диапазоне от -0.5 до 0.5.

Код реализации:

```
```python
Выбор признака
feature_name = 'alcohol'
feature_data = df[feature_name].copy()

Mean Normalisation
mean_val = feature_data.mean()
min_val = feature_data.min()
max_val = feature_data.max()
range_val = max_val - min_val
feature_normalized = (feature_data - mean_val) / range_val
```

Результаты статистического анализа:

До нормализации:

- Среднее значение: 13.0006

- Минимальное значение: 11.0300
- Максимальное значение: 14.8300

После нормализации:

- Среднее значение: 0.0000
- Минимальное значение: -0.5443
- Максимальное значение: 0.5029

Дополнительным требованием для группы ИУ5И-22М является построение гистограммы. На рисунке 3 представлены гистограммы распределения признака 'alcohol' до и после нормализации, а также боксплот для сравнения распределений.




Рисунок 3: Визуализация результатов Mean Normalisation (гистограммы, боксплот, линейный график)

### Часть 3. Задача №36

Задача №39 - Для набора данных проведите процедуру отбора признаков (feature selection). Используйте класс SelectPercentile для 10% лучших признаков, и метод, основанный на взаимной информации.

Для выполнения задачи использовался тот же набор данных Wine Dataset. Целевой переменной является тип вина (target). Признаками служат все 13 числовых характеристик.

Был применен класс SelectPercentile с параметром percentile=10 (выбор 10% лучших признаков) и функцией оценки mutual\_info\_classif, так как задача является задачей классификации.

Результаты вычисления взаимной информации (Mutual Information) для каждого признака представлены в таблице ниже.

Код реализации:

```
from sklearn.feature_selection import SelectPercentile, mutual_info_classif
```

```
X = df.drop('target', axis=1)
```

```
y = df['target']
```

```
selector = SelectPercentile(mutual_info_classif, percentile=10)
```

```
selector.fit(X, y)
```

```
selected_features = X.columns[selector.get_support()].tolist()
```

Таблица 1 - Значения взаимной информации для каждого признака

Признак	MI Score
flavanoids	0.6676

Признак	MI Score
proline	0.5774
color_intensity	0.5483
od280/od315_of_diluted_wines	0.5162
alcohol	0.4743
hue	0.4664
total_phenols	0.4016
proanthocyanins	0.3054
malic_acid	0.2824
alcalinity_of_ash	0.2378
magnesium	0.2134
nonflavanoid_phenols	0.1210
ash	0.0792

Было выбрано 2 признака из 13 (10% от общего числа):

1. flavanoids (MI Score: 0.6676)
2. proline (MI Score: 0.5774)

На рисунке 4 представлена визуализация результатов отбора признаков: горизонтальная столбчатая диаграмма MI Score и круговая диаграмма соотношения выбранных и невыбранных признаков.




Рисунок 4: Визуализация результатов отбора признаков SelectPercentile + Mutual Information

#### Часть 4. Дополнительные требования(гистограмма)

В соответствии с дополнительным требованием для группы ИУ5И-22М, для произвольной колонки данных была построена гистограмма. Для этого был выбран признак 'alcohol' (содержание алкоголя) из набора данных Wine Dataset.

На рисунке 3 (представленном в Части 2) уже показаны гистограммы распределения признака 'alcohol' до и после нормализации. Отдельно, на рисунке 5, представлена гистограмма исходного распределения признака 'alcohol' до применения любой обработки.




Рисунок 5: Гистограмма распределения признака 'alcohol' в исходном наборе данных Wine Dataset

Гистограмма позволяет визуально оценить форму распределения данных. В данном случае распределение содержания алкоголя близко к нормальному, что хорошо видно по колоколообразной форме гистограммы.

## ЗАКЛЮЧЕНИЕ

В ходе выполнения рубежного контроля №1 по дисциплине «Методы машинного обучения» была проведена комплексная работа по обработке и анализу данных на основе набора данных Wine Dataset (набор данных о винах), содержащего 178 образцов и 13 числовых признаков.

В рамках задачи №19 была успешно применена процедура масштабирования данных с использованием метода Mean Normalisation к числовому признаку «alcohol» (содержание алкоголя). Преобразование было выполнено по формуле  $X_{norm} = (X - \text{mean}(X)) / (\text{max}(X) - \text{min}(X))$ . В результате преобразования среднее значение признака стало равно 0, а диапазон значений изменился с [11.03, 14.83] до [-0.5443, 0.5029]. Форма распределения при этом сохранилась, что подтверждает корректность выполненного масштабирования.

Для задачи №39 была выполнена процедура отбора признаков с применением класса SelectPercentile (percentile=10%) и метода, основанного на взаимной информации (Mutual Information). В результате было выявлено, что наибольшее значение взаимной информации с целевой переменной (типом вина) имеют признаки «flavanoids» (0.6676) и «proline» (0.5774). Эти два признака были отобраны как 10% лучших признаков. Остальные 11 признаков были признаны менее информативными для данной задачи классификации.

Дополнительным требованием для группы ИУ5И-22М было построение гистограммы для произвольной колонки данных. Для признака «alcohol» была построена гистограмма, которая наглядно показала распределение содержания алкоголя в образцах вин трех различных типов.

Таким образом, все поставленные задачи (№19 и №39) были успешно выполнены с использованием единого набора данных Wine Dataset, а также

соблюдены все дополнительные требования к оформлению отчета и визуализации результатов.

## Приложение: Скриншоты кода

```
=====
ЗАДАЧА №19: Mean Normalisation (Масштабирование с помощью среднего значения)
TASK №19: Mean Normalisation (Mean Normalization)
=====

Выбор произвольного числового признака для масштабирования
选择一个任意的数值特征进行均值归一化

Выбираем признак 'alcohol' (алкоголь) для демонстрации
选择 'alcohol' (酒精含量) 特征作为演示
feature_name = 'alcohol'
feature_data = df[feature_name].copy()

print("=" * 60)
print("ЗАДАЧА №19: Mean Normalisation")
print("TASK №19: Mean Normalisation")
print("=" * 60)
print(f"\nВыбранный признак: '{feature_name}'")
print(f"选择特征: '{feature_name}'")
print(f"Описание: содержание алкоголя в вине")
print(f"描述: 葡萄酒中的酒精含量")

Статистика до нормализации
归一化前的统计信息
print("\n" + "-" * 40)
print("ДО НОРМАЛИЗАЦИИ / 归一化前:")
print("-" * 40)
print(f"Среднее (mean): {feature_data.mean():.4f}")
print(f"Минимум (min): {feature_data.min():.4f}")
print(f"Максимум (max): {feature_data.max():.4f}")
print(f"Стандартное отклонение (std): {feature_data.std():.4f}")

Формула Mean Normalisation:
$X_{norm} = (X - \text{mean}(X)) / (\text{max}(X) - \text{min}(X))$
均值归一化公式: $X_{norm} = (X - \text{均值}) / (\text{最大值} - \text{最小值})$

mean_val = feature_data.mean()
min_val = feature_data.min()
max_val = feature_data.max()
range_val = max_val - min_val

feature_normalized = (feature_data - mean_val) / range_val
```

```

Статистика после нормализации
归一化后的统计信息
print("\n" + "-" * 40)
print("ПОСЛЕ НОРМАЛИЗАЦИИ / 归一化后:")
print("-" * 40)
print(f"Среднее (mean): {feature_normalized.mean():.4f}")
print(f"Минимум (min): {feature_normalized.min():.4f}")
print(f"Максимум (max): {feature_normalized.max():.4f}")
print(f"Стандартное отклонение (std): {feature_normalized.std():.4f}")

Проверка свойств Mean Normalisation
检查均值归一化的性质
print("\n" + "-" * 40)
print("ПРОВЕРКА СВОЙСТВ / 性质验证:")
print("-" * 40)
print(f"Среднее значение после нормализации: {feature_normalized.mean():.10f} (должно быть ~0)")
print(f"归一化后的均值: {feature_normalized.mean():.10f} (应该约等于0)")
print(f"Диапазон после нормализации: [{feature_normalized.min():.4f}, {feature_normalized.max():.4f}]")
print(f"归一化后的范围: [{feature_normalized.min():.4f}, {feature_normalized.max():.4f}]")

```

```

=====
ЗАДАЧА №19: Mean Normalisation
TASK №19: Mean Normalisation
=====

```

Выбранный признак: 'alcohol'  
 Выбор特征: 'alcohol'  
 Описание: содержание алкоголя в вине  
 描述: 葡萄酒中的酒精含量

-----  
 ДО НОРМАЛИЗАЦИИ / 归一化前:  
 -----

Среднее (mean): 13.0006  
 Минимум (min): 11.0300  
 Максимум (max): 14.8300  
 Стандартное отклонение (std): 0.8118

-----  
 ПОСЛЕ НОРМАЛИЗАЦИИ / 归一化后:  
 -----

Среднее (mean): -0.0000  
 Минимум (min): -0.5186  
 Максимум (max): 0.4814  
 Стандартное отклонение (std): 0.2136

-----  
 ПРОВЕРКА СВОЙСТВ / 性质验证:  
 -----

Среднее значение после нормализации: -0.0000000000 (должно быть ~0)  
 归一化后的均值: -0.0000000000 (应该约等于0)  
 Диапазон после нормализации: [-0.5186, 0.4814]  
 归一化后的范围: [-0.5186, 0.4814]

```
=====
ЗАДАЧА №39: Отбор признаков с помощью SelectPercentile и взаимной информации
TASK №39: Feature selection using SelectPercentile and mutual information
=====

print("=" * 60)
print("ЗАДАЧА №39: SelectPercentile (10% лучших признаков) + Mutual Information")
print("TASK №39: SelectPercentile (10% best features) + Mutual Information")
print("=" * 60)

Подготовка данных
准备数据
X = df.drop('target', axis=1) # Признаки / 特征
y = df['target'] # Целевая переменная / 目标变量

print("\nИсходные данные / 原始数据:")
print(f" - Количество образцов / 样本数: {X.shape[0]}")
print(f" - Количество признаков / 特征数: {X.shape[1]}")
print(f" - Целевая переменная: классификация на 3 класса (типы вина)")
print(f" - 目标变量: 3分类问题 (葡萄酒类型)")

Расчет взаимной информации для каждого признака
计算每个特征的互信息得分
mi_scores = mutual_info_classif(X, y, random_state=42)

Создание DataFrame с результатами
创建包含结果的DataFrame
mi_df = pd.DataFrame({
 'Признак / Feature': X.columns,
 'MI Score': mi_scores
}).sort_values('MI Score', ascending=False)

print("\n" + "-" * 60)
print("ВЗАИМНАЯ ИНФОРМАЦИЯ ДЛЯ КАЖДОГО ПРИЗНАКА")
print("每个特征的互信息得分")
print("-" * 60)
print(mi_df.to_string(index=False))

SelectPercentile: выбираем 10% лучших признаков
SelectPercentile: 选择前10%的最佳特征
percentile = 10
selector = SelectPercentile(mutual_info_classif, percentile=percentile)
selector.fit(X, y)

Получение маски выбранных признаков
获取所选特征的掩码
selected_mask = selector.get_support()
selected_features = X.columns[selected_mask].tolist()
```

```
Количество выбранных признаков
所选特征的数量
n_features = X.shape[1]
n_selected = len(selected_features)
print(f"\nвыбрано {n_selected} из {n_features} признаков ({percentile}% лучших)")
print(f"从 {n_features} 个特征中选择了 {n_selected} 个特征 (<{percentile}%最佳)")

print("\n" + "-" * 60)
print("ВЫБРАННЫЕ ПРИЗНАКИ (10% лучших) / SELECTED FEATURES (10% best)")
print("-" * 60)

Вывод информации о выбранных признаках
输出所选特征的信息
for i, feat in enumerate(selected_features, 1):
 score = mi_df[mi_df['Признак / Feature'] == feat]['MI Score'].values[0]
 print(f"{i}. {feat:35s} | MI Score: {score:.6f}")

Признаки, которые НЕ были выбраны
未被选中的特征
not_selected = [f for f in X.columns if f not in selected_features]
if not_selected:
 print("\n" + "-" * 60)
 print("НЕВЫБРАННЫЕ ПРИЗНАКИ / NOT SELECTED FEATURES")
 print("-" * 60)
 for feat in not_selected:
 score = mi_df[mi_df['Признак / Feature'] == feat]['MI Score'].values[0]
 print(f"❌ {feat:35s} | MI Score: {score:.6f}")
```

=====

ЗАДАЧА №39: SelectPercentile (10% лучших признаков) + Mutual Information

TASK №39: SelectPercentile (10% best features) + Mutual Information

=====

Исходные данные / 原始数据:

- Количество образцов / 样本数: 178
- Количество признаков / 特征数: 13
- Целевая переменная: классификация на 3 класса (типы вина)
- 目标变量: 3分类问题 (葡萄酒类型)

-----

ВЗАИМНАЯ ИНФОРМАЦИЯ ДЛЯ КАЖДОГО ПРИЗНАКА

每个特征的互信息得分

-----

Признак / Feature	MI Score
flavanoids	0.667602
proline	0.577391
color_intensity	0.548274
od280/od315_of_diluted_wines	0.516158
alcohol	0.474312
hue	0.466412
total_phenols	0.401599
proanthocyanins	0.305406
malic_acid	0.282384
alcalinity_of_ash	0.237806
magnesium	0.213352
nonflavanoid_phenols	0.120971
ash	0.079201

Выбрано 2 из 13 признаков (10% лучших)

从 13 个特征中选择了 2 个特征 (前10%最佳)

-----

ВЫБРАННЫЕ ПРИЗНАКИ (10% лучших) / SELECTED FEATURES (10% best)

-----

1. flavanoids	MI Score: 0.667602
2. proline	MI Score: 0.577391

-----

НЕВЫБРАННЫЕ ПРИЗНАКИ / NOT SELECTED FEATURES

-----

✗ alcohol	MI Score: 0.474312
✗ malic_acid	MI Score: 0.282384
✗ ash	MI Score: 0.079201
✗ alcalinity_of_ash	MI Score: 0.237806
✗ magnesium	MI Score: 0.213352
✗ total_phenols	MI Score: 0.401599
✗ nonflavanoid_phenols	MI Score: 0.120971
✗ proanthocyanins	MI Score: 0.305406
✗ color_intensity	MI Score: 0.548274
✗ hue	MI Score: 0.466412
✗ od280/od315_of_diluted_wines	MI Score: 0.516158